

Customer 360

Plataforma Inteligente para Segmentación,
Riesgo y Rentabilidad de Clientes Bancarios

Fase 1 — Entendimiento del Negocio
Business Understanding

Tabla de contenido

1. Contexto
2. Objetivos
3. Stakeholders
4. Preguntas de negocio
5. KPIs del dashboard ejecutivo
6. Alcance del proyecto
7. Entregables
8. Criterios de éxito
9. Limitaciones de diseño y recomendaciones arquitectónicas

1. Contexto

Un banco cuenta con miles de clientes que realizan transacciones, solicitan créditos, utilizan tarjetas, contratan seguros y mantienen distintos productos financieros. Actualmente la información se encuentra distribuida en diferentes sistemas, lo que dificulta responder preguntas estratégicas sobre rentabilidad, riesgo y fidelización de clientes.

La gerencia solicita construir una plataforma analítica que integre esta información y facilite la toma de decisiones basada en datos, cubriendo cuatro dimensiones de análisis: valor del cliente, riesgo crediticio, fidelización y rentabilidad. El enfoque no se limita a describir lo ocurrido: la plataforma debe anticipar comportamientos futuros mediante modelos predictivos conectados directamente al dashboard ejecutivo.

Nota sobre los datos: Los datos utilizados en este proyecto son sintéticos, generados artificialmente para fines de portafolio. La generación incluye ruido controlado, anomalías de comportamiento y estacionalidad en transacciones para garantizar que los modelos sean evaluados en condiciones representativas. Los campos `comision_pct` y `costo_fondeo_pct` son supuestos documentados, no tarifas reales de mercado vigentes.

2. Objetivos

2.1 Objetivo general

Desarrollar una solución de análisis de datos que consolide la información de clientes, permita segmentarlos según su comportamiento financiero, estime su nivel de riesgo, anticipe el abandono y genere indicadores que apoyen las decisiones comerciales y estratégicas del banco, transitando de un enfoque descriptivo hacia uno predictivo y prescriptivo.

2.2 Objetivos específicos

- Centralizar la información de clientes y productos (cuentas, tarjetas, préstamos, seguros) en una base de datos relacional PostgreSQL.
- Analizar el comportamiento financiero de los clientes mediante indicadores clave (KPIs) descriptivos y predictivos.
- Identificar segmentos de clientes utilizando técnicas RFM y clustering (K-Means).
- Estimar la probabilidad individual de abandono (churn) por cliente para habilitar campañas de retención proactivas.
- Estimar el riesgo crediticio e identificar el monto en riesgo latente en la cartera vigente.
- Aproximar la rentabilidad por cliente y por producto, ajustada por costo de fondeo (supuesto documentado).
- Construir un dashboard ejecutivo en Power BI que conecte los modelos de Machine Learning con acciones de negocio concretas.
- Generar recomendaciones de negocio accionables, incluyendo una estructura de campaña piloto de retención con impacto económico estimado.

3. Stakeholders

La siguiente tabla identifica a los principales usuarios de la plataforma y su necesidad específica, lo cual determina qué información debe priorizarse en cada sección del dashboard ejecutivo.

Stakeholder	Necesidad	Vista clave en el dashboard
Gerente Comercial	Identificar clientes rentables y oportunidades de venta cruzada.	Rentabilidad + segmentos con potencial de cross-selling
Gerente de Riesgos	Detectar clientes con alta probabilidad de incumplimiento crediticio.	Monto en Riesgo Latente + score dinámico por cliente
Equipo de Marketing	Diseñar campañas personalizadas por segmento de cliente.	Lista descargable: clientes en riesgo de abandono
Ejecutivos de Cuenta	Conocer el perfil y riesgo de cada cliente antes de ofrecer productos.	Vista 360° individual por cliente
Director de Banca Personas	Tener una visión integral del negocio mediante KPIs ejecutivos.	Resumen ejecutivo con todos los KPIs

4. Preguntas de negocio

Todo análisis desarrollado en las fases siguientes debe estar orientado a responder estas preguntas concretas, agrupadas por dimensión de análisis. Las preguntas marcadas con (*) son de naturaleza predictiva y se responden con los modelos de Machine Learning de la Fase 6.

4.1 Clientes

- ¿Quiénes son los clientes más valiosos para el banco?
- ¿Qué clientes generan mayores ingresos?
- ¿Qué segmentos de clientes existen según su comportamiento financiero?
- ¿Cómo varía el comportamiento de los clientes por edad, ciudad o tipo de cliente?
- ¿Qué canales prefieren los distintos segmentos de clientes?

4.2 Riesgo

- (*) ¿Qué clientes tienen alta probabilidad de incumplir el pago de un préstamo?
- ¿Qué porcentaje de la cartera presenta riesgo de incumplimiento?
- (*) ¿Cuál es el monto en riesgo latente en créditos vigentes según el modelo predictivo?
- ¿Qué variables explican mejor el riesgo crediticio?

4.3 Fidelización

- (*) ¿Qué clientes tienen mayor probabilidad de abandonar el banco en los próximos 90 días?
- ¿Qué características comparten los clientes que abandonan?
- ¿Qué clientes deberían recibir promociones de retención de forma prioritaria?

4.4 Productos

- ¿Qué producto debería ofrecerse a cada segmento de cliente?
- ¿Qué productos generan mayores ingresos para el banco?
- ¿Qué combinaciones de productos son más frecuentes entre los clientes?
- ¿Qué campañas tendrían mayor probabilidad de éxito según el segmento?

4.5 Rentabilidad

- ¿Qué segmento de clientes aporta más ingresos al banco?
- ¿Cuál es el ingreso promedio por cliente?
- ¿Qué ciudades o canales son más rentables?
- ¿Cuál es el impacto económico estimado de reducir el churn en un segmento específico?

5. KPIs del dashboard ejecutivo

Estos indicadores constituyen el núcleo del dashboard ejecutivo (Fase 7) y deben poder calcularse directamente a partir del modelo estrella definido en Fase 2. Los KPIs se organizan en dos niveles: descriptivos, que resumen lo ocurrido, y predictivos, que muestran la salida de los modelos de Machine Learning para anticipar y accionar.

5.1 Clientes

KPI	Definición	Fuente
Total de clientes	Conteo de clientes registrados	Dim_Cliente
Clientes activos	Clientes con al menos una transacción en los últimos 90 días	Fact_Transacciones
Clientes inactivos	Clientes sin transacciones en los últimos 90 días	Fact_Transacciones
Clientes nuevos	Clientes con fecha de registro dentro del período analizado	Dim_Cliente

5.2 Rentabilidad

KPI	Definición	Fuente
Ingreso total	Suma de ingreso_comision más ingreso_estimado de préstamos	Fact_Transacciones, Fact_Prestamos
Ingreso promedio por cliente	Ingreso total dividido entre el total de clientes activos	Calculado
Ticket promedio	Monto promedio por transacción	Fact_Transacciones
Margen estimado	Ingreso financiero menos costo de fondeo (supuesto documentado)	Fact_Prestamos
Potencial de cross-selling	Clientes con menos de dos productos activos y alto ingreso mensual, candidatos a oferta cruzada	Dim_Cliente, Fact_Productos_Contratados

5.3 Productos

KPI	Definición	Fuente
Cuentas activas	Conteo de cuentas con estado = Activa	Cuenta
Número de tarjetas	Conteo de tarjetas por tipo (Débito / Crédito)	Tarjeta
Créditos vigentes	Conteo de préstamos con estado = Vigente	Préstamo
Seguros activos	Conteo de seguros con estado = Activo	Seguro
Productos por cliente	Promedio de productos contratados por cliente (UNION Cuenta + Tarjeta + Préstamo + Seguro)	Calculado

5.4 Riesgo

KPI	Definición	Fuente
Índice de morosidad	% de préstamos con es_default = TRUE	Fact_Prestamos
Score promedio	Promedio de score_riesgo entre préstamos vigentes	Fact_Prestamos
Cientes de alto riesgo	Cientes con score_riesgo por debajo del umbral definido en Fase 6	Fact_Prestamos
Monto en riesgo	Suma del monto de préstamos con es_default = TRUE	Fact_Prestamos
Monto en Riesgo Latente	Suma del monto de créditos vigentes cuyos clientes presentan score_riesgo deteriorado según el modelo predictivo. Permite anticipar pérdidas antes de que se materialicen.	Fact_Prestamos + Modelo de Riesgo

5.5 Fidelización

KPI	Definición	Fuente
Tasa de abandono (churn)	% de clientes con cuentas inactivas por más del umbral definido en Fase 6	Cuenta, Fact_Transacciones
Cientes recuperables	Cientes con inactividad moderada, candidatos a campañas de reactivación	Calculado
Cientes perdidos	Cientes con inactividad prolongada y sin productos vigentes	Calculado
Cientes en Riesgo de Abandono	Lista de clientes activos con alta probabilidad de churn según el modelo (XGBoost / Random Forest). Incluye probabilidad individual, segmento RFM y canal preferido. Exportable para campañas de retención.	Modelo de Churn (Fase 6)
Ingreso en Riesgo por Churn	Suma del ingreso estimado de los clientes clasificados con riesgo de abandono. Cuantifica el impacto económico potencial para priorizar la acción comercial.	Modelo de Churn + Fact_Prestamos

6. Alcance del proyecto

Para mantener el proyecto en un alcance manejable como ejercicio de portafolio, se delimitan explícitamente los procesos de negocio representados.

Incluye

- Diseño de base de datos relacional (modelo normalizado) y modelo estrella (Data Warehouse).
- Gestión de clientes, cuentas, tarjetas (modelo simplificado), préstamos, pagos, seguros (modelo simplificado), canales y agencias.
- Proceso ETL: generación de datos sintéticos con ruido controlado, anomalías de comportamiento y estacionalidad en transacciones, limpieza, transformación y carga en PostgreSQL.
- Consultas SQL analíticas (top clientes, rentabilidad, morosidad, uso por canal).
- Análisis exploratorio de datos (EDA) e ingeniería de variables en Python.
- Modelos de Machine Learning: segmentación (RFM + K-Means), riesgo crediticio (Regresión Logística + Random Forest) y churn (XGBoost o Random Forest).
- Dashboard ejecutivo en Power BI con vistas descriptivas y predictivas conectadas a los modelos de Machine Learning.
- Documentación completa y presentación ejecutiva final con recomendaciones accionables.

No incluye

- Integración con sistemas bancarios reales (los datos son sintéticos, generados para fines del proyecto).
- Procesamiento en tiempo real.
- Despliegue en la nube ni desarrollo de aplicaciones móviles.
- Detalle de consumos y ciclos de facturación de tarjetas de crédito.
- Gestión de siniestros y reclamos de seguros.
- Inversiones, bolsa de valores, tipo de cambio e hipotecas.
- Implementación del ciclo de retroalimentación (Feedback Loop); se documenta como recomendación arquitectónica en la sección 9.

7. Entregables

- Documento de requerimientos (este documento).
- Diccionario de datos y reglas de negocio.
- Modelo entidad-relación (ERD) y modelo estrella.
- Base de datos relacional en PostgreSQL (scripts SQL de creación).
- Notebooks de Python (EDA, ingeniería de variables, generación de datos sintéticos, modelos de ML).
- Modelos de Machine Learning entrenados, evaluados y calibrados.
- Dashboard ejecutivo en Power BI.
- Informe ejecutivo con hallazgos, recomendaciones accionables y estructura de campaña piloto de retención.

8. Criterios de éxito

El proyecto se considerará exitoso si:

Criterios técnicos

- El dashboard ejecutivo permite responder todas las preguntas de negocio planteadas en la sección 4.
- Los datos están correctamente integrados, documentados y respetan las reglas de negocio definidas en Fase 2.
- Los modelos predictivos alcanzan un desempeño adecuado (ROC-AUC superior a 0.80 en el modelo de riesgo, evaluando también precisión, recall y calibración, no solo exactitud).
- Los datos sintéticos incluyen ruido y anomalías documentadas; los modelos son evaluados sobre un conjunto de prueba representativo para evitar el sobreajuste.
- El código es reproducible y está organizado en un repositorio público de GitHub.

Criterios de negocio

Estos criterios traducen los resultados técnicos a lenguaje de impacto económico, relevante para la gerencia.

Criterio	Descripción	Forma de medición
Campaña piloto de retención estructurada	Las recomendaciones permiten diseñar una campaña piloto capaz de mitigar teóricamente al menos el 60-70% del ingreso en riesgo por abandono, identificando el segmento objetivo, el canal de contacto y el mensaje sugerido.	Ingreso en Riesgo por Churn $\times$ tasa de éxito estimada del modelo
Ahorro potencial por detección proactiva de riesgo	El modelo de riesgo crediticio permite identificar créditos en riesgo latente antes del incumplimiento, cuantificando el monto que podría protegerse con una política de crédito preventiva.	Monto en Riesgo Latente identificado por el modelo
Oportunidad de cross-selling cuantificada	Se identifica el segmento de clientes con mayor potencial de contratación de productos adicionales, estimando el ingreso incremental potencial.	Clientes con potencial $\times$ ingreso promedio por producto adicional

9. Limitaciones de diseño y recomendaciones arquitectónicas

9.1 Limitaciones conocidas

Se documentan explícitamente las simplificaciones adoptadas para mantener el proyecto en un alcance de portafolio. Reconocer estas limitaciones es parte de los criterios de calidad del proyecto.

Ausencia de dimensiones con cambio histórico (SCD)

Dim_Cliente contiene atributos que pueden cambiar en el tiempo, como ciudad e ingreso_mensual. Al no implementar Slowly Changing Dimensions (SCD Tipo 2), un cambio en estos valores sobrescribe el historial. En un entorno productivo real se requerirían campos fecha_inicio_vigencia, fecha_fin_vigencia y un indicador de registro vigente.

ETL en dos pasadas

Los campos score_riesgo y segmento_rfm dependen de los modelos de Machine Learning de Fase 6 y no pueden cargarse en la primera ejecución del ETL. El proceso debe ejecutarse en dos fases: carga inicial con estos campos en NULL y actualización posterior al modelado. El pipeline documenta y automatiza este orden.

Rentabilidad aproximada

El campo margen_estimado es una aproximación de primer nivel ($\text{ingreso_estimado} - \text{costo_fondeo_estimado}$). No incorpora pérdida esperada ($\text{PD} \times \text{LGD} \times \text{EAD}$) ni costos operativos. Los resultados son ilustrativos, no constituyen un estado financiero.

Datos sintéticos versus producción

Aunque la generación de datos incluye ruido y anomalías, el desempeño real de los modelos en datos bancarios reales podría diferir. Los resultados del proyecto son demostrativos y no deben interpretarse como proyecciones operativas.

9.2 Recomendaciones arquitectónicas

Las siguientes recomendaciones describen cómo debería evolucionar el sistema en una versión productiva. No se implementan en el proyecto actual pero se documentan para demostrar visión de sistema.

Ciclo de retroalimentación (Feedback Loop)

El diseño actual detecta y predice, pero no aprende de los resultados de las acciones tomadas. En una versión productiva, el sistema debería implementar un ciclo de mejora continua:

1. El modelo predice que un cliente tiene alta probabilidad de abandono.
2. Marketing lanza una campaña de retención personalizada.
3. El cliente responde y permanece activo.
4. Esa transacción exitosa se registra como nuevo dato de entrenamiento.
5. El modelo se reentrena periódicamente incorporando estos resultados reales.
6. Con el tiempo, el sistema aprende qué acciones funcionaron para qué perfiles de cliente.

Score de riesgo dinámico

El score_riesgo actual se calcula una vez y se almacena de forma estática. En producción debería recalcularse periódicamente (mensual o ante eventos de mora) para capturar el deterioro progresivo de la

calidad crediticia de un cliente, haciendo que el KPI de Monto en Riesgo Latente sea verdaderamente dinámico.

Calibración del umbral de churn por segmento

El umbral de clasificación del modelo de churn debería calibrarse por segmento de cliente, dado que el costo de un falso negativo varía según el valor del cliente. Para un cliente de alto valor, conviene reducir el umbral de decisión y activar la retención incluso ante menor certeza del modelo.